

Fiscalização automatizada de fotos de leitura de medidores de energia elétrica: um pipeline de OCR e caracterização do problema de validação de coerência

[Autoria omitida para revisão duplo-cega]

Resumo

Distribuidoras de energia elétrica fiscalizam periodicamente a leitura de medidores por meio de fotografias registradas por leituristas em campo, posteriormente conferidas por equipes de analistas quando sinalizadas como potencialmente inconsistentes. Esse processo manual, sujeito a alto volume — dezenas de milhares de imagens mensais — gera sobrecarga operacional e variação de julgamento entre analistas. Este trabalho apresenta um pipeline de visão computacional off-the-shelf voltado a duas tarefas complementares: a leitura óptica do display do medidor e a validação de coerência entre a fotografia e a ocorrência registrada em campo. O pipeline combina detecção e reconhecimento de texto (PaddleOCR, TrOCR) com heurísticas de orientação, seleção de leitura e identificação do medidor via assinatura de tokens. Avaliado no conjunto público UFPR-ADMR, o melhor reconhecedor testado alcança 84,6% de acurácia por dígito e 35,7% de leituras exatas. Para a validação de coerência, descreve-se o levantamento de uma base real de campo — cerca de 12,3 mil fotografias e um catálogo de 61 códigos de ocorrência — obtida junto a uma distribuidora, ainda carente do rótulo de decisão da fiscalização necessário ao treino supervisionado. Discutem-se as limitações dos modelos prontos e um caminho de trabalho futuro fundamentado nos dados já disponíveis.

Palavras-chave: visão computacional; OCR; medidores de energia; fiscalização automatizada; aprendizado de máquina.

Automated fiscalization of meter-reading photographic evidence in electric utilities: an OCR pipeline and characterization of the coherence-validation problem

Abstract

Electric utilities periodically audit meter readings through photographs taken by field technicians, which analyst teams later review whenever they are flagged as potentially inconsistent. This manual process, subject to high volume — tens of thousands of images per month — causes operational overload and inconsistent judgment across analysts. This work presents an off-the-shelf computer-vision pipeline for two complementary tasks: optical reading of the meter display and coherence validation between the photograph and the occurrence code registered in the field. The pipeline combines text detection and recognition (PaddleOCR, TrOCR) with orientation heuristics, reading selection, and meter identification via a token-based signature. Evaluated on the public UFPR-ADMR dataset, the best recognizer tested reaches 84.6% digit accuracy and 35.7% exact-match readings. For coherence validation, the work describes the acquisition of a real field dataset — about 12,300 photographs and a catalog of 61 occurrence codes — obtained from a utility, still lacking the fiscalization decision label required for supervised training. Limitations of off-the-shelf models are discussed alongside a future-work path grounded in the data already available.

Keywords: computer vision; OCR; energy meters; automated auditing; machine learning.

Fiscalização automatizada de fotos de leitura de medidores de energia elétrica: um pipeline de OCR e caracterização do problema de validação de coerência

1. INTRODUÇÃO

A confiabilidade do faturamento em distribuidoras de energia elétrica depende, em grande medida, da leitura periódica dos medidores instalados nas unidades consumidoras. Essa leitura é realizada por leituristas em campo, que fotografam o display do medidor como evidência do atendimento e, quando a leitura convencional não é possível — por imóvel fechado, desocupado, demolido ou de acesso impedido — registram uma ocorrência que justifica a ausência do valor lido. Esses registros fotográficos alimentam o processo de fiscalização que sustenta a confiabilidade das informações de faturamento.

Parte dessas fotografias é sinalizada como potencialmente inconsistente e encaminhada para validação manual. Em operações de grande porte, esse volume varia entre 50 e 70 mil imagens mensais, analisadas por uma equipe reduzida de seis analistas/validadores que verificam, uma a uma, se a evidência apresentada é suficiente e compatível com o registro efetuado em campo. O elevado número de análises aumenta a carga operacional da equipe, contribui para a realização de horas extras e introduz variação de julgamento entre analistas distintos.

O problema não se resume à qualidade técnica da imagem — iluminação, desfoque, enquadramento, rotação — mas também à sua coerência com o contexto da visita, o que exige considerar a diversidade de medidores e configurações de medição, incluindo unidades com geração própria de energia.

A leitura óptica de displays de medidores tem recebido atenção crescente da comunidade de visão computacional, com conjuntos de dados e baselines públicos voltados especificamente a medidores brasileiros, e com o avanço geral de detectores e reconhecedores de texto em cena. Esses trabalhos, no entanto, tratam majoritariamente da tarefa isolada de reconhecer os dígitos em um recorte já centrado no display, e pouco tratam da composição desses componentes em um pipeline que opere sobre a fotografia de campo completa — sujeita a rotação arbitrária, medidores mecânicos com dígitos claros sobre fundo escuro e concorrência com outros textos na cena, como a placa de identificação do medidor.

Mais significativamente, a decisão que de fato interessa à fiscalização — se a evidência fotográfica é suficiente e coerente com a ocorrência registrada pelo leiturista — é um problema de classificação de cena e contexto, distinto do reconhecimento de dígitos, para o qual não foi identificado um conjunto de dados público que associe fotografias de campo aos códigos de ocorrência aplicados.

Este trabalho tem como objetivo geral avaliar e documentar uma abordagem de visão computacional para tornar a fiscalização de evidências fotográficas de leitura mais eficiente e padronizada, preservando a atuação humana nos casos que exigem julgamento especializado.

Especificamente, o trabalho (i) avalia modelos de detecção e reconhecimento de texto prontos, sem ajuste fino, na leitura de displays de medidores em um conjunto de dados público brasileiro; (ii) descreve um conjunto de decisões de engenharia que estendem esses modelos a fotografias de campo, incluindo detecção de orientação, inferência em duas fases para medidores mecânicos com dígitos invertidos e uma assinatura do medidor para

reidentificação sem depender de um número de série legível; e (iii) relata o levantamento de uma base real de fotografias de campo, obtida junto a uma distribuidora de energia, que caracteriza o problema de validação de coerência e delimita exatamente o que falta para viabilizar seu treino supervisionado.

2. CONTEXTO

Esta seção situa o trabalho em relação à literatura de leitura óptica de medidores e de detecção/reconhecimento de texto em cena (2.1), argumenta pela ausência de um problema equivalente já resolvido para a validação de coerência entre evidência fotográfica e ocorrência de campo (2.2) e descreve os dados e métricas usados na avaliação da Tarefa 1 (2.3).

2.1 Leitura óptica de medidores e reconhecimento de texto em cena

A literatura de leitura óptica de medidores brasileiros compreende dois conjuntos de dados irmãos, de mesma origem institucional e nomes semelhantes, por vezes confundidos entre si. Laroca et al. (2019) introduziram o UFPR-AMR, 2.000 imagens de medidores digitais — contadores de cinco dígitos fixos —, com partição oficial de 800 imagens de treino, 400 de validação e 800 de teste. Salomon, Laroca e Menotti (2020) introduziram, na sequência, o UFPR-ADMR, conjunto irmão também com 2.000 imagens, mas de medidores de mostrador (dial), cujo número de dígitos varia por modelo e cuja partição oficial é de 1.200 imagens de treino, 400 de validação e 400 de teste. O conjunto usado na avaliação deste trabalho (Seção 2.3) corresponde ao domínio de mostrador: os medidores mecânicos com dígitos claros sobre fundo escuro, discutidos na Seção 3, são precisamente o tipo de medidor que motivou a criação do UFPR-ADMR, não do UFPR-AMR original. Essa distinção de proveniência importa porque justifica por que a inferência em duas fases (Seção 3) — desnecessária para o contador de dígitos fixos do UFPR-AMR — é central neste trabalho.

A leitura de medidores de mostrador introduz um desafio estrutural ausente em contadores digitais: o dígito em trânsito entre duas posições da roda, parcialmente visível durante a rotação mecânica, cuja interpretação correta segue uma convenção de arredondamento — em geral, o menor dos dois dígitos adjacentes, já que a leitura registra o consumo acumulado até aquele instante, não o valor para o qual a roda está avançando. Esse desafio é bem documentado na literatura de leitura automática de mostradores mecânicos e está ausente, por construção, no contador de dígitos fixos do UFPR-AMR: um reconhecedor treinado apenas em dígitos plenamente formados carece de qualquer sinal para arbitrar entre dois candidatos igualmente nítidos. Este trabalho não propõe uma solução dedicada a esse caso — os reconhecedores avaliados na Seção 4.1 são usados sem ajuste fino específico para dígitos em trânsito —, mas a fração de leituras incorretas por confusão de dígito adjacente, em vez de falha de detecção, é uma hipótese de erro que qualquer trabalho futuro de ajuste fino sobre o UFPR-ADMR precisará isolar separadamente da taxa agregada de exact-match.

Fora do domínio de medidores, duas famílias de modelos de propósito geral sustentam grande parte dos sistemas de OCR aplicados: a família PP-OCR (PADDLEPADDLE, [20--]) do PaddlePaddle, que combina um detector de texto baseado em binarização diferenciável — a rede DBNet (Liao et al., 2020), que aprende um mapa de limiares e de probabilidades para produzir contornos de texto sem pós-processamento heurístico de caixas — com reconhecedores leves treinados para texto de cena em geral; e o TrOCR (Li et al., 2023), um modelo transformer encoder-decoder que combina um encoder de visão pré-treinado com um decoder de linguagem pré-treinado, ajustado em seguida sobre corpora sintéticos de texto impresso e manuscrito antes do ajuste fino em dados reais.

Nenhuma dessas famílias foi treinada especificamente para displays de medidores — sua aplicação ao domínio depende de composição com pré-processamento e pós-processamento específicos, o que motiva as decisões de pipeline descritas na Seção 3.

A diversidade de tipos de medidor discutida na Seção 1 não é exclusiva de medidores de energia elétrica: Ebadi et al. (2021) introduziram o NRC-GAMMA, um conjunto de quase 29 mil imagens de um único medidor de gás capturado ao longo de um dia inteiro de operação, voltado à leitura de mostradores duplos. A existência de conjuntos de dados especializados por tipo de medidor e por concessionária — elétrica, gás, mecânica, digital — reforça o argumento da Seção 1: um pipeline que dependa de recorte manual por tipo de medidor não escala para a diversidade de configurações encontrada em operação real, o que motiva a ênfase deste trabalho em decisões de pré-processamento (Seção 3) capazes de generalizar entre esses regimes sem re-treino específico por tipo.

2.2 Validação de evidência fotográfica em processos de fiscalização

O problema de decidir se uma fotografia constitui evidência suficiente e coerente com uma ocorrência registrada é, em essência, um problema de classificação de cena e contexto: a mesma ausência de leitura no display pode ser esperada (imóvel fechado, demolido) ou indicar uma inconsistência, a depender da ocorrência aplicada. Não foi identificado, na literatura consultada, um conjunto de dados público que associe fotografias de campo de medidores de energia a códigos de ocorrência equivalentes aos utilizados operacionalmente pelas distribuidoras.

Três candidatos com proveniência identificável foram mapeados durante o levantamento deste trabalho — nenhum deles ficou acessível dentro do prazo, por exigirem contato direto com os autores e concessão de licença acadêmica. O primeiro é o Copel-AMR (Laroca et al., 2021), 12.500 fotografias de campo coletadas pelos próprios funcionários de uma distribuidora brasileira, incluindo 2.500 imagens de medidores com defeito ou leitura ilegível por oclusão — o mais próximo, entre os três, do cenário de fotografia de campo completa tratado neste trabalho, mas restrito a validação de legibilidade, sem códigos de ocorrência. O segundo é o UFPR-ADMR-v2 (Salomon, Laroca e Menotti, sucessor do UFPR-ADMR descrito em 2.1), aproximadamente 5 mil imagens de medidores de mostrador de segunda geração. O terceiro, menor, é um conjunto de 570 imagens indexado no IEEE DataPort por pesquisadores do IIT (BHU) Varanasi, sob assinatura paga da plataforma, não sob solicitação acadêmica direta. Em nenhum dos três o rótulo estruturado de ocorrência de fiscalização — o elemento central da Seção 3.2 — está presente; todos endereçam legibilidade ou qualidade de imagem, não coerência entre fotografia e evento registrado.

A barreira de acesso a esses três candidatos não é meramente burocrática. O licenciamento do Copel-AMR, por exemplo, exige que o termo de uso seja assinado por autoridade institucional — coordenação de curso ou chefia de departamento — sem que a assinatura de um aluno ou professor isoladamente seja aceita, o que introduz um tempo de tramitação institucional dificilmente compatível com o prazo de um trabalho de curso ou de uma submissão com data fixa. O UFPR-ADMR-v2 segue processo equivalente, também mediado por contato direto com os autores. O conjunto do IEEE DataPort, por sua vez, está condicionado a uma assinatura paga da plataforma, uma barreira econômica distinta das duas anteriores, mas igualmente incompatível com acesso aberto imediato. Essas três barreiras — burocrática, institucional e econômica — ilustram por que a validação de coerência carece de um benchmark de acesso aberto mesmo quando dados equivalentes já foram coletados por outros grupos: a existência do dado não implica sua disponibilidade para comparação direta entre abordagens, o que reforça, novamente, o valor de documentar o processo de

levantamento primário relatado na Seção 3.2 com granularidade suficiente para que outras distribuidoras possam reproduzi-lo sem depender de um único ponto de acesso institucional.

Essa lacuna é distinta da lacuna de leitura óptica discutida em 2.1: enquanto o reconhecimento de dígitos dispõe de benchmarks públicos consolidados, a validação de coerência carece inteiramente de um conjunto de dados de referência de acesso aberto, o que motiva o levantamento de dados primários relatado na Seção 3.2. Essa dependência de negociação de acesso é, em si, uma barreira à reprodutibilidade de qualquer trabalho futuro sobre validação de coerência: mesmo quando um conjunto de dados equivalente existe, sua indisponibilidade sob licença aberta limita a comparação direta entre abordagens propostas por grupos distintos, o que reforça o valor de relatar, como feito na Seção 3.2, o processo de levantamento de dados primários com o nível de detalhe necessário para que outros possam reproduzi-lo junto a outras distribuidoras.

A distinção entre UFPR-AMR e UFPR-ADMR (Seção 2.1) também é relevante para a validação de coerência: leituras de comprimento variável, como as de medidores de mostrador, tornam qualquer heurística de validação sensível ao formato mais frágil do que no caso de um contador de dígitos fixos — mais um motivo para que os sinais de coerência propostos na Seção 3.1 sejam agnósticos ao comprimento da leitura, em vez de assumir um formato fixo.

2.3 Dados e métricas de avaliação da leitura óptica

A avaliação da Tarefa 1 utiliza o conjunto de teste do UFPR-ADMR (Seção 2.1), particionado, no mirror consultado — `Chaymaa/UFPR-AMR`, Hugging Face Hub, <https://huggingface.co/datasets/Chaymaa/UFPR-AMR>, acesso em 25 ago. 2026 —, em 1.400 imagens de treino, 300 de teste e 300 de validação — partição distinta da oficial (1.200/400/400) reportada por Salomon, Laroca e Menotti (2020), embora preserve o total de 2.000 imagens do conjunto original; o subconjunto de teste (300 imagens) é o usado para benchmark. O comprimento médio das leituras é de aproximadamente 4,5 dígitos, variável por modelo de mostrador — ao contrário do contador de cinco dígitos fixos do UFPR-AMR (Seção 2.1).

Duas métricas são reportadas: exact-match, a fração de imagens cuja leitura predita é idêntica ao rótulo; e digit-acc, a acurácia por dígito, calculada alinhando a predição ao rótulo da direita para a esquerda, o que a torna robusta a variações no comprimento da leitura predita. Por transparência, quando o modelo de decodificação emite tokens separados por espaço (caso do TrOCR com busca em feixe), reportam-se tanto a métrica bruta — que conta o espaço como caractere — quanto a métrica após remoção dos espaços, diretamente comparável aos reconhecedores que não emitem esse separador.

O problema de fiscalização abordado neste trabalho é delimitado por um recorte operacional específico, que o distingue de atividades correlatas, porém não equivalentes: não integram esse recorte o cálculo tarifário, a manutenção da rede elétrica, a investigação de fraude e a cobrança financeira, ainda que todas dependam indiretamente da confiabilidade da leitura registrada. A validação manual das fotografias sinalizadas é hoje realizada por uma equipe de seis analistas/validadores (Seção 1), responsável pelo volume mensal de 50 a 70 mil imagens potencialmente inconsistentes. Considerando um mês típico de aproximadamente 21 dias úteis, essa proporção corresponde a uma faixa de cerca de 400 a 555 imagens por analista por dia útil — uma ordem de grandeza que ajuda a explicar a sobrecarga operacional e as horas extras mencionadas na Seção 1, e que situa a motivação deste trabalho: não a substituição do julgamento humano, mas a redução seletiva do volume que efetivamente precisa dele.

Essa delimitação orienta diretamente o desenho descrito na Seção 3: os sinais de coerência emitidos pelo pipeline (Seção 3.1) foram concebidos como insumos de triagem — candidatos a aprovação automática ou a atenção prioritária — não como um veredito que substitua a análise manual nos casos de maior incerteza.

3. MÉTODO

O pipeline proposto, denominado MeterOCR, é composto por quatro etapas sequenciais: detecção de caixas de texto, reconhecimento do conteúdo de cada caixa, classificação de cada trecho reconhecido por campo (leitura ou número de série) e seleção da leitura final. A detecção utiliza o PP-OCRv5_mobile_det (ONNX), com pós-processamento por binarização diferenciável (limiar 0,3; limiar de caixa 0,6; fator de expansão 1,5); como a rede exige dimensões múltiplas de 32 pixels, a imagem de entrada é ajustada por preenchimento, com posterior remapeamento das coordenadas das caixas detectadas para a imagem original.

O reconhecimento é realizado prioritariamente pelo TrOCR-small-printed, com contingência para o PP-OCRv6_tiny quando o primeiro retorna resultado vazio — combinação que busca aliar a fidelidade do TrOCR à robustez do PP-OCRv6 em casos degenerados. Cada trecho reconhecido é então classificado como leitura (apenas dígitos, aceitando ponto, vírgula ou espaço como separadores, entre um e oito dígitos) ou como número de série (alfanumérico, de seis a vinte e quatro caracteres, excluindo símbolos típicos de placas de identificação). A leitura final prioriza trechos compostos apenas por dígitos e, entre estes, o de maior número de dígitos, sem concatenar caixas detectadas isoladamente — o que evitaria a formação de leituras espúrias em fotografias de cena completa.

Fotografias de campo diferem substancialmente dos recortes centrados de display presentes nos conjuntos de dados públicos: chegam em orientação arbitrária e, no caso de medidores mecânicos (odômetros), apresentam dígitos claros sobre fundo escuro — padrão oposto ao texto escuro sobre fundo claro em que o detector foi treinado. Quatro decisões de engenharia respondem a essas condições.

Detecção de orientação antes da leitura. Em vez de testar múltiplas rotações da imagem — estratégia custosa e sujeita a decisões precipitadas quando mais de uma rotação produz resultado plausível — o pipeline estima a orientação correta antes de acionar o reconhecimento: executa a detecção sobre uma versão reduzida da imagem (640 pixels) e pontua a fração de área ocupada por caixas de texto predominantemente horizontais após a fusão de caixas adjacentes na mesma linha.

Inferência em duas fases. A primeira fase processa a imagem na orientação estimada, com caixas de texto fundidas por linha; a segunda processa a imagem invertida (claro-em-escuro), com caixas tratadas individualmente, sem fusão. Displays de odômetros mecânicos só se tornam legíveis nessa segunda fase; cada caixa detectada carrega a informação de qual das duas fases a originou.

Nova tentativa com inversão da imagem. Quando a leitura não é localizada na primeira fase, o pipeline inverte a imagem e refaz detecção e reconhecimento sobre os quadrantes individuais, sem fusão — evitando juntar o display a textos adjacentes na cena, como a própria placa de identificação do medidor.

Assinatura do medidor. Todo trecho reconhecido que não é classificado como leitura — número de série e texto da placa de identificação — compõe uma assinatura do medidor: os tokens são normalizados (maiúsculas, apenas caracteres alfanuméricos, dois ou mais caracteres), ordenados por posição na imagem e reduzidos a um hash SHA-1 de doze

caracteres. A similaridade entre duas assinaturas, calculada pelo índice de Jaccard sobre os conjuntos de tokens, permite reidentificar o mesmo medidor entre fotografias distintas mesmo quando o número de série não está legível em uma delas.

3.1 Sinais de coerência emitidos pelo pipeline

Embora não constitua um classificador de coerência propriamente dito, o pipeline já emite sinais diretamente aproveitáveis como sementes para essa tarefa: nitidez do recorte avaliado, estimada pela variância do operador de Laplace e exposta como valor contínuo (a Seção 4.3 discute por que um limiar fixo herdado de outro domínio não é adequado sem recalibração); ausência de leitura detectada; presença de múltiplas leituras concorrentes na mesma imagem; e ausência de número de série reconhecido. Esses sinais, combinados ao catálogo de ocorrências descrito a seguir, delimitam o espaço de features de um futuro classificador de coerência.

3.2 Levantamento de uma base real para a validação de coerência

Para caracterizar concretamente o problema de validação de coerência, foi obtida junto a uma distribuidora de energia uma amostra real de operação: quatro lotes diários de extração, somando 12.340 fotografias de campo e 13.669 linhas de registro, cada lote acompanhado de uma tabela que associa o número do medidor, a posição de leitura registrada, a ocorrência aplicada pelo leitorista (quando houver) e o arquivo de fotografia correspondente. Um documento complementar cataloga 61 códigos de ocorrência distintos, indicando para cada um se o procedimento operacional exige o registro de fotografia — 32 códigos exigem, entre eles os que registram imóvel fechado (ocupado, desocupado ou em veraneio), imóvel demolido e substituição de medidor. A Tabela 2 apresenta as ocorrências mais frequentes na amostra.

Código	Descrição	Ocorrências (% do total)
— (NA)	Leitura normal, sem ocorrência	9.109 (66,6%)
T181	Função Não Existe no Sistema	2.595 (19,0%)
P111	E.M. Substituído ou Número Incorreto	685 (5,0%)
L101	Leitura Informada Pelo Cliente	496 (3,6%)
T111	Caixa/Tampa Embaçada/Danificada — com leitura	358 (2,6%)
B111	Local de Consumo Implantado em Duplicidade	123 (0,9%)
L131	Campanha 2	97 (0,7%)

Tabela 2 – Ocorrências mais frequentes na base de campo analisada (13.669 registros, 4 lotes).

Fonte: elaborado pelos autores (2026), a partir de base de campo cedida por uma distribuidora de energia.

A inspeção dessa amostra confirma a diversidade de situações antecipada na literatura, e revela padrões que não eram evidentes a partir da documentação operacional isolada. Do total de linhas com nota normal (NA, leitura obtida sem ocorrência), 79,8% ainda assim têm fotografia associada, indicando que o registro fotográfico não se restringe a casos excepcionais. Cerca de 9,6% dos registros trazem dois números de medidor separados por barra (dois identificadores numéricos de dez dígitos); testada a hipótese óbvia de que isso decorreria de substituição de equipamento, ela não se sustenta — apenas 3,6% desses casos carregam a ocorrência de substituição (P111), enquanto 58% ocorrem em linhas de leitura normal, sugerindo uma causa estrutural ainda não identificada.

Por fim, das 3.943 linhas cuja ocorrência exige fotografia, 7,5% não têm arquivo de imagem associado, concentradas em apenas três códigos. Nenhuma dessas inconsistências invalida a

base; elas delimitam, ao contrário, o tipo de ruído que um classificador de coerência treinado sobre esses dados precisará tolerar.

O elemento que ainda falta nessa base, e que é o pré-requisito direto para treino supervisionado de um classificador de coerência, é o rótulo da decisão final da fiscalização — se cada fotografia foi aceita ou rejeitada pela equipe de análise. Sem esse rótulo, a base permite caracterizar o problema, dimensionar a distribuição de ocorrências e guiar o desenho de um piloto de anotação manual, mas não sustenta ainda um treino supervisionado direto. Observa-se também que nenhum dos quatro lotes disponíveis contém ocorrências do tipo “imóvel fechado” ou “imóvel demolido” (códigos I1xx/D1xx do catálogo), o que sugere que a amostra atual não cobre todo o espectro de situações operacionais e que lotes adicionais serão necessários antes de qualquer treino.

3.3 Considerações éticas e de tratamento de dados

As fotografias de campo utilizadas neste trabalho podem conter, além do medidor, elementos de fachada, portão, numeração predial e, ocasionalmente, pessoas — dados pessoais e de geolocalização implícita no sentido da Lei Geral de Proteção de Dados Pessoais (Lei nº 13.709/2018). O tratamento desses dados neste trabalho seguiu três princípios operacionais: a base bruta permanece em armazenamento local, fora de controle de versão e sem redistribuição; nenhuma fotografia individual é reproduzida neste artigo; e as estatísticas relatadas são agregadas, sem exposição de números de medidor, endereços ou identificadores de cliente.

Um fluxo de anonimização (por exemplo, desfoque automático de rostos e placas veiculares porventura capturados) e um termo de uso específico para fins de pesquisa acadêmica são pré-requisitos identificados para qualquer uso da base além da caracterização estatística aqui relatada, e permanecem como pendência a esclarecer junto à distribuidora.

Este trabalho não foi submetido a comitê de ética em pesquisa (CEP): trata-se de dados operacionais obtidos por acordo direto com a distribuidora, sem contato com pessoas identificadas como sujeitos de pesquisa e sem exposição pública de imagens individuais. Qualquer extensão deste trabalho que envolva coleta direta junto a leituristas, analistas ou clientes — por exemplo, entrevistas para validar o piloto de anotação proposto na Seção 4.4 — exigirá submissão formal a um CEP, nos termos da Resolução CNS nº 466/2012.

4. RESULTADOS E DISCUSSÃO

4.1 Benchmark de leitura óptica (Tarefa 1)

A Tabela 1 apresenta o desempenho dos reconhecedores avaliados no conjunto de teste do UFPR-ADMR, sem qualquer ajuste fino nos dados do domínio.

Modelo	exact-match	digit-acc	Observação
PP-OCRV6_tiny_rec (1,1M parâmetros)	0,357	0,846	decodificação CTC, sem espaço
TrOCR-small-printed (62M parâmetros)	0,160	0,642	métrica bruta (conta espaço do feixe)
TrOCR-small-printed (idem)	0,253	0,776	métrica limpa (espaços removidos)

Tabela 1 – Benchmark off-the-shelf no conjunto de teste do UFPR-ADMR (300 imagens).

Fonte: elaborado pelos autores (2026), a partir do conjunto de teste do UFPR-ADMR (Salomon et al., 2020).

O PP-OCRv6_tiny obtém o melhor resultado agregado entre os modelos testados, tanto em leituras exatas quanto em acurácia por dígito, apesar de possuir substancialmente menos parâmetros que o TrOCR. O TrOCR-small-printed, por não ter sido treinado para displays de medidores, tende a fragmentar a leitura em tokens separados por espaço; quando essa fragmentação é desfeita, seu desempenho por dígito se aproxima do PP-OCRv6, mas sua taxa de leituras inteiramente corretas permanece inferior.

Em comparação, Salomon, Laroca e Menotti (2020) reportam, com um reconhecedor por CNN (Faster R-CNN, backbone ResNext-101) treinado especificamente sobre o UFPR-ADMR, taxa de 93,6% por mostrador individual e 75,25% por leitura completa do medidor. O PP-OCRv6_tiny usado aqui sem qualquer ajuste fino aproxima-se dessa referência na métrica por dígito (84,6% contra 93,6%, unidades de comparação distintas — mostrador individual versus dígito isolado —, mas de mesma natureza), porém fica substancialmente abaixo na leitura completa (35,7% contra 75,25%). Essa distância é o custo esperado de dispensar o ajuste fino: o reconhecedor genérico acerta a maioria dos dígitos individualmente, mas erra a leitura como um todo com frequência bem maior que um modelo treinado no domínio, o que delimita com precisão o ganho que um ajuste fino futuro sobre o UFPR-ADMR poderia capturar.

Esses resultados sugerem que, para a leitura completa do display sem ajuste fino, um reconhecedor leve e especializado em texto de cena tende a generalizar melhor que um modelo de OCR genérico de maior capacidade — achado consistente com a natureza do domínio, em que o vocabulário é restrito a dígitos e a principal fonte de erro é a segmentação de caracteres, não a modelagem de linguagem.

4.2 Achados de campo do pipeline completo

A inspeção qualitativa de fotografias de campo (fora do recorte padronizado do UFPR-ADMR) indica que a detecção de orientação por fração de área horizontal acertou a orientação correta nos seis casos de teste examinados, incluindo um medidor mecânico cujo display só se torna legível após a inversão descrita na Seção 3. Em um caso específico, um odômetro Landis+Gyr não produz leitura alguma sem a etapa de inversão e produz a leitura correta (41365) quando essa etapa é acionada — evidência direta de que a estratégia de duas fases é necessária, não apenas uma robustez marginal, para esse tipo de medidor.

Esses achados são qualitativos e derivam de um conjunto reduzido de fotografias de campo; sua confirmação em escala requer avaliação sistemática sobre uma amostra maior, o que a base descrita na Seção 3.2 poderá viabilizar assim que doada de rótulo de decisão.

Um achado quantificado, obtido a partir da mesma amostra usada no teste empírico da Seção 4.3, reforça a motivação por trás da assinatura do medidor descrita na Seção 3: em todos os dez grupos de ocorrência avaliados, o sinalizador mais frequente emitido pelo pipeline é “serial não detectado” — presente em 248 das 382 fotografias da amostra (65,0%), com incidência mínima de 47,5% (P111) e máxima de 95,0% (L101).

Isso indica que a maioria das fotografias de campo enquadra apenas o display do medidor, sem capturar a placa de identificação ou o número de série — um padrão de enquadramento que qualquer estratégia de reidentificação baseada unicamente em número de série encontraria com frequência alta o suficiente para inviabilizá-la operacionalmente, e que justifica, retrospectivamente, a opção por uma assinatura combinada de tokens (Seção 3) em vez de depender de um único campo estruturado.

4.3 Sinais de coerência sem rótulo: teste empírico contra a semântica da ocorrência

Na ausência do rótulo de aceite/rejeição, testou-se uma hipótese mais fraca, porém verificável com os dados disponíveis: os sinais que o pipeline já emite (Seção 3.1) deveriam se correlacionar com o que a própria semântica da ocorrência registrada sugere, mesmo sem qualquer treino supervisionado. Duas hipóteses iniciais foram testadas com um script interno de avaliação: (H1) fotografias com a ocorrência T111 (“Caixa/Tampa Embaçada/Danificada — com leitura”, que documenta obstrução visual da caixa de medição apesar de a leitura existir) deveriam apresentar taxa de “leitura não detectada” maior que fotografias com nota normal (NA); (H2) fotografias com a ocorrência L101 (“Leitura Informada Pelo Cliente”, aplicada quando o leitor não conseguiu obter a leitura por si e recorreu à informação do cliente) deveriam apresentar o mesmo padrão.

O teste foi então ampliado das duas notas originais para as nove ocorrências mais frequentes da base, cobrindo tanto códigos de semântica visual/física quanto códigos puramente administrativos, para verificar se o sinal discrimina seletivamente ou dispara de forma inespecífica para qualquer ocorrência.

O resultado (Tabela 3) mostra, no grupo NA (n=40), 37,5% das fotografias sem leitura detectada; no grupo T111, a taxa é de 57,5% (teste exato de Fisher contra NA, $p=0,12$); no grupo L101, de 72,5% ($p=0,003$), a maior de toda a tabela. Os códigos administrativos apresentam taxas iguais ou abaixo do baseline: T181 25,0% ($p=0,33$), T161 27,5% ($p=0,47$), P111 32,5% ($p=0,81$), R111 36,4% ($p=1,00$, $n=22$). Entre os demais códigos de semântica visual/física, M141 (52,5%, $p=0,26$), B111 (40,0%, $p=1,00$) e L131 (42,5%, $p=0,82$) também não atingem significância a 5%.

Apenas L101 atinge significância estatística contra o baseline NA — mesmo sob correção de Bonferroni para as nove comparações simultâneas (limiar ajustado $p<0,0056$), o resultado se sustenta. Os demais quatro códigos de semântica visual/física (T111, M141, B111, L131) mostram elevação na direção hipotetizada, mas o teste exato de Fisher não permite descartar a hipótese nula com $n=40$ por grupo — o desenho é subdimensionado para detectar efeitos dessa magnitude com confiança. Isso não invalida a hipótese de seletividade semântica, mas a rebaixa de resultado confirmado para achado preliminar que requer amostra maior: a ausência de significância em quatro dos cinco grupos hipotetizados é, por si, uma limitação a declarar, não evidência definitiva de que o sinal discrimina por tipo de ocorrência de forma geral. O contraste mais robusto que os dados atuais sustentam é o de L101 especificamente, não uma seletividade ampla da classe “visual/física” contra a classe administrativa.

Grupo (nota)	Amostr a	% sem leitura detectada	% ilegível (Laplaciano)	p (Fisher vs. NA)
NA (baseline)	40	37,5%	12,5%	—
T181 (função não existe no sistema)	40	25,0%	15,0%	0,33
P111 (medidor substituído)	40	32,5%	5,0%	0,81
L101 (leitura via cliente)	40	72,5%	0,0%	0,003*
T111 (caixa obstruída/danificada)	40	57,5%	22,5%	0,12
B111 (implantado em duplicidade)	40	40,0%	10,0%	1,00
L131 (campanha)	40	42,5%	20,0%	0,82
T161 (função não existe no medidor)	40	27,5%	7,5%	0,47
M141 (registrador parado, desabitado)	40	52,5%	12,5%	0,26
R111 (medidor alocado incorretamente)	22	36,4%	4,5%	1,00

Tabela 3 – Sinais de coerência por grupo de ocorrência, 10 grupos (amostra real, sem treino supervisionado).

Fonte: elaborado pelos autores (2026), a partir do teste empírico descrito na Seção 4.3. p-valor pelo teste exato de Fisher, cada grupo contra o baseline NA; * significativo mesmo sob correção de Bonferroni para nove comparações (limiar ajustado $p < 0,0056$).

A coluna de ilegibilidade da Tabela 3 só é confiável a partir de uma correção de cobertura feita durante esta avaliação: numa primeira execução, a checagem de nitidez (variância do Laplaciano, Seção 3.1) só era aplicada quando uma leitura já havia sido localizada, deixando os casos sem leitura — a maioria da amostra — sem qualquer avaliação, o que produzia uma taxa de ilegibilidade artificialmente nula em todos os grupos. Corrigiu-se o pipeline para aplicar a checagem também nesses casos, usando como substituto a maior caixa detectada na cena, e para expor o valor contínuo da variância como telemetria, em vez de apenas um booleano preso a um limiar fixo.

Com a correção, a ilegibilidade diverge entre os grupos de forma semanticamente coerente, e não na mesma direção da taxa de “leitura não detectada”: T111 tem a maior taxa de ilegibilidade (22,5%, contra 12,5% no grupo NA), consistente com sua semântica de problema óptico na cena. Já L101, apesar de ter a maior taxa de leitura não detectada, apresenta a *menor* taxa de ilegibilidade (0,0%) de toda a tabela — suas fotografias tendem a ser nítidas, apenas sem um display legível na cena.

Essa divergência sugere dois mecanismos de falha distintos: T111 aponta para um problema de qualidade da imagem (borrão, obstrução física), enquanto L101 aponta para um problema de ausência de alvo (medidor não fotografado de frente, inacessível, ou substituído por informação verbal do cliente) que uma métrica de nitidez pura não captura. Um classificador de coerência completo precisará dos dois sinais separadamente, não de um único indicador combinado.

Os valores medidos tornam essa divergência concreta: no grupo T111, os percentis 10/50/90 da variância do Laplaciano são 8,5/87,0/1.444,4, com o percentil 10 abaixo de qualquer limiar razoável de legibilidade; no grupo L101, os mesmos percentis são 460,8/2.755,2/9.312,8 — mais de cinquenta vezes o piso de T111 — confirmando numericamente que as fotografias desse grupo são nítidas, apenas sem um alvo legível na cena.

4.3.1 Validação cruzada da nitidez contra gabarito real (UFPR-ADMR)

A divergência da Tabela 3 mostra que a ilegibilidade discrimina entre grupos de ocorrência, mas não prova que ela discrimina corretamente entre foto boa e foto ruim — a base de campo não tem esse rótulo. Buscou-se uma validação independente no único conjunto com gabarito real disponível: o UFPR-ADMR (Seção 2.3), comparando a nitidez do recorte com o acerto/erro do reconhecedor PP-OCRv6 no benchmark da Seção 4.1.

O resultado foi negativo: a correlação de Pearson entre nitidez e acerto exato foi de -0,002, e um teste de discriminação por pares aleatórios (probabilidade de uma imagem corretamente lida ter nitidez maior que uma incorretamente lida) resultou em 0,426 — abaixo mesmo do acaso (0,5). Ou seja, no domínio onde existe gabarito, a variância do Laplaciano isoladamente **não prediz** se o reconhecedor vai acertar a leitura. Duas explicações não excludentes: os recortes do UFPR-ADMR já foram pré-selecionados pelos curadores do dataset (pouca variação de nitidez sobra para discriminar), e os erros do reconhecedor nesse benchmark provavelmente derivam mais de confusão entre dígitos do que de borrão da imagem.

Esse resultado reforça a cautela já adotada de não fixar um novo limiar sem rótulo de referência do próprio domínio de aplicação (fotografias de campo, não recortes de display) — a nitidez pode ainda ser útil combinada a outras features, mas não como preditor único.

4.4 Ameaças à validade e custo operacional

Três limitações de validade merecem destaque. Primeiro, representatividade: os quatro lotes disponíveis não contêm nenhuma ocorrência dos tipos “imóvel fechado” ou “imóvel demolido” (Seção 3.2), que estão entre os cenários mais discutidos na literatura interna do projeto sobre o problema — a caracterização aqui relatada cobre o que a amostra permite, não o espectro completo do catálogo de 61 códigos.

Segundo, escala da avaliação de campo: os achados da Seção 4.2 e 4.3 derivam de dezenas a poucas centenas de fotografias, não da base de 12,3 mil imagens em sua totalidade — suficiente para testar hipóteses pontuais, insuficiente para estimar taxas de erro com confiança estatística.

Terceiro, custo computacional: mediu-se formalmente a latência de inferência em ambiente de CPU (sem aceleração por GPU) sobre as 382 fotografias das avaliações da Seção 4.3 — média de 4,43 segundos por imagem, mediana de 1,4 segundos, percentil 90 de 13,2 segundos e máximo de 27,3 segundos.

A cauda longa corresponde aos casos que acionam a segunda fase de inferência (imagem invertida, Seção 3); a mediana bem abaixo da média indica que a maioria das fotografias é processada rapidamente, com uma minoria de casos difíceis puxando o tempo médio para cima. Esse perfil é adequado a um processamento em lote noturno da fila de validação (382 imagens processadas em pouco mais de 28 minutos), mas inviabilizaria, no estado atual, uma resposta em tempo real durante a visita do leitorista.

Quarto, ruído estrutural no próprio conjunto de campo: a Seção 3.2 já identificou que 9,6% dos registros trazem dois números de medidor separados por barra sem explicação estrutural clara, e que 7,5% das linhas cuja ocorrência exige fotografia não têm arquivo associado, concentradas em três códigos. Um piloto de anotação supervisionada herdar esse ruído, o que recomenda uma etapa de triagem e limpeza prévia à anotação — em particular, excluir do primeiro lote os registros com número de medidor ambíguo ou fotografia ausente, para não contaminar o rótulo desde a primeira iteração do classificador.

Os achados das Seções 4.2 e 4.3 permitem esboçar, com concretude parcial, um caminho para superar a lacuna identificada na Seção 3.2 — a ausência do rótulo de decisão da fiscalização. Em vez de um piloto de anotação abrangendo os 61 códigos do catálogo, o resultado estatisticamente confirmado da Tabela 3 sugere priorizar, num primeiro lote, o grupo L101 — o único, entre os cinco hipotetizados como visuais/físicos, com desvio significativo em relação ao baseline NA (Seção 4.3) — e tratar T111, M141, B111 e L131 como candidatos de segunda prioridade, cuja elevação direcional ainda carece de confirmação em amostra maior. Essa priorização, mais conservadora que a sugerida por uma leitura apenas descritiva da Tabela 3, reduz o volume de anotação manual necessário para validar cada hipótese isoladamente antes de comprometer recursos com o catálogo completo.

Em termos de escala, um piloto de mil a duas mil fotografias distribuídas entre esses cinco grupos — uma fração pequena da base de 12,3 mil imagens já levantada (Seção 3.2) — seria suficiente para treinar um classificador supervisionado simples sobre os sinais já emitidos pelo pipeline, sem exigir novos ciclos de coleta de dados.

Considerando a proporção de seis analistas para o volume mensal estimada na Seção 2.3, um piloto dessa escala representaria uma fração pequena da carga de revisão de um único dia útil — um custo de anotação compatível com validação incremental, e não uma reformulação do processo operacional vigente. O resultado negativo da validação cruzada de nitidez (Seção 4.3.1) reforça, adicionalmente, que esse classificador não deve depender de um único sinal: a combinação de features é o desenho recomendado, não a busca por um substituto único do julgamento humano.

Do ponto de vista de features, o piloto proposto pode reaproveitar diretamente as saídas já produzidas pelo pipeline sem qualquer reengenharia: a variância do Laplaciano como valor contínuo (não mais o booleano herdado do limiar de 25, corrigido na Seção 4.3), o número de leituras candidatas detectadas, a presença ou ausência de número de série, e a similaridade de assinatura do medidor (Seção 3) entre a fotografia analisada e um histórico de fotografias anteriores do mesmo ponto de medição — um sinal ainda não explorado nos testes empíricos das Seções 4.3 e 4.3.1, mas que poderia detectar, por exemplo, uma fotografia enviada para um medidor diferente do esperado na unidade consumidora.

Essa é a extensão mais direta do trabalho atual: os componentes já existem no pipeline, restando apenas o rótulo supervisionado para transformá-los em um classificador treinado.

5. CONCLUSÃO

Este trabalho avaliou um pipeline de visão computacional off-the-shelf para a leitura óptica de medidores de energia elétrica e documentou um conjunto de decisões de engenharia — detecção de orientação, inferência em duas fases, seleção de leitura resistente a heurísticas espúrias e assinatura do medidor por hash de tokens — que estendem modelos de propósito geral a fotografias de campo. Os resultados indicam que reconhecedores leves e especializados em texto de cena, mesmo sem ajuste fino, superam um modelo de OCR genérico de maior porte na leitura completa do display, embora ambos permaneçam distantes de uma taxa de leituras exatas adequada a uso irrestrito em produção.

Para a validação de coerência entre fotografia e ocorrência registrada, o trabalho relata o levantamento de uma base real de campo que resolve a lacuna de dados identificada na literatura, mas evidencia que a lacuna remanescente não é de volume de imagens, e sim do rótulo de decisão da fiscalização. Esse é o passo necessário indicado como trabalho futuro, junto ao ajuste fino dos reconhecedores sobre dados de campo e à integração dos sinais de coerência já emitidos pelo pipeline — legibilidade, ausência ou multiplicidade de leituras, ausência de série — como features de um classificador supervisionado.

O teste empírico sobre dez grupos de ocorrência (Seção 4.3) indica que ao menos um sinal — a ausência de leitura detectada no grupo L101 — discrimina com significância estatística confirmada (teste exato de Fisher, $p=0,003$) frente ao baseline de ocorrência normal; os demais quatro grupos de semântica visual/física hipotetizados mostram a mesma direção sem atingir significância na amostra atual, o que qualifica a viabilidade do caminho proposto como parcialmente sustentada, não integralmente demonstrada. Ao mesmo tempo, a validação cruzada contra o gabarito real do UFPR-ADMR (Seção 4.3.1) mostra que a nitidez isolada não é suficiente como preditor, reforçando que o classificador final precisará combinar múltiplos sinais, não apenas um. A Seção 4.4 traduz esses achados em um roteiro operacional concreto — piloto de anotação priorizado pelo grupo com desvio já confirmado, com os demais grupos visuais/físicos como segunda prioridade —, em escala compatível com a capacidade de revisão já existente, que reduz a lacuna remanescente a um passo de execução em grande parte, ainda que não integralmente, resolvido.

O uso de dados reais de campo, obtidos junto a uma distribuidora, também impõe uma responsabilidade de tratamento que este trabalho assumiu de forma restritiva (Seção 3.3): a base bruta não é redistribuída, nenhuma fotografia individual é exposta e as estatísticas relatadas são agregadas. A definição de um fluxo formal de anonimização e de um termo de uso específico para pesquisa acadêmica é pré-requisito para qualquer expansão do uso dessa base além da caracterização aqui apresentada.

As limitações deste trabalho incluem: a ausência de ajuste fino dos modelos de reconhecimento ao domínio de medidores; a detecção de número de série por heurística de formato, sem um detector dedicado, sujeita a ruído proveniente da placa de identificação; o uso da variância do Laplaciano como sinal de legibilidade, um proxy simples e não um rótulo validado; e a validação qualitativa do pipeline completo sobre um número reduzido de fotografias de campo. Superar essas limitações depende, em grande medida, do mesmo insumo: acesso continuado a dados reais de operação, dos quais a base descrita na Seção 3.2 é um primeiro passo concreto.

REFERÊNCIAS

- EBADI, A.; PAUL, P.; AUER, S.; TREMBLAY, S. NRC-GAMMA: Introducing a Novel Large Gas Meter Image Dataset. [S. l.]: arXiv, 2021. Pré-publicação, arXiv:2111.06827. Disponível em: <https://arxiv.org/abs/2111.06827>. Acesso em: 8 set. 2026.
- LAROCA, R. et al. Convolutional Neural Networks for Automatic Meter Reading. *Journal of Electronic Imaging*, v. 28, n. 1, art. 013023, 2019. DOI: 10.1117/1.JEI.28.1.013023.
- LAROCA, R. et al. Towards Image-based Automatic Meter Reading in Unconstrained Scenarios: A Robust and Efficient Approach. *IEEE Access*, v. 9, p. 67569–67584, 2021. DOI: 10.1109/ACCESS.2021.3077415.
- LI, M. et al. TrOCR: Transformer-based Optical Character Recognition with Pre-trained Models. In: *AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE*, 37., 2023. Anais [...]. Washington, DC: AAAI, 2023. Pré-publicação, arXiv:2109.10282. Disponível em: <https://arxiv.org/abs/2109.10282>. Acesso em: 8 set. 2026.
- LIAO, M. et al. Real-Time Scene Text Detection with Differentiable Binarization. In: *AAAI CONFERENCE ON ARTIFICIAL INTELLIGENCE*, 34., 2020. Anais [...]. New York: AAAI, 2020. Pré-publicação, arXiv:1911.08947. Disponível em: <https://arxiv.org/abs/1911.08947>. Acesso em: 8 set. 2026.
- PADDLEPADDLE. PaddleOCR: modelos de detecção e reconhecimento de texto em cena. [20--]. Repositório de código. Disponível em: <https://github.com/PaddlePaddle/PaddleOCR>. Acesso em: 25 ago. 2026.
- SALOMON, G.; LAROCA, R.; MENOTTI, D. Deep Learning for Image-based Automatic Dial Meter Reading: Dataset and Baselines. In: *INTERNATIONAL JOINT CONFERENCE ON NEURAL NETWORKS (IJCNN)*, 2020. Anais [...]. Glasgow: IEEE, 2020. DOI: 10.1109/IJCNN48605.2020.9207318.